

# MS211 - Cálculo Numérico

Aula 5 – Normas de Vetores e Matrizes.  
Condicionamento de uma Matriz.



**UNICAMP**

Marcos Eduardo Valle

Na aula anterior, falamos sobre os erros de arredondamento na representação de ponto flutuante e suas operações aritméticas.

---

Em termos gerais, erros sempre existirão quando resolvemos um problema contínuo (e.g. em  $\mathbb{R}$ ) num computador.

---

Consequentemente, um método numérico raramente produz a solução exata de um problema matemático contínuo.

---

Na aula de hoje, veremos quando o arredondamento em ponto flutuante e suas operações aritméticas influenciam na credibilidade do resultado produzido por um método numérico.

---

Iniciaremos apresentando a definição de norma, conceito matemático utilizado para medir tamanho ou distância.

## Definição 1 (Norma)

Uma norma é uma função  $\| \cdot \|$ , de um espaço vetorial  $\mathcal{V}$  no conjunto dos reais  $\mathbb{R}$ , que satisfaz as seguintes propriedades para quaisquer  $u, v \in \mathcal{V}$  e  $\alpha \in \mathbb{R}$ :

1.  $\|v\| \geq 0$  com  $\|v\| = 0$  se e somente se  $v = 0$ .
2.  $\|\alpha v\| = |\alpha| \|v\|$ .
3.  $\|u + v\| \leq \|u\| + \|v\|$ . (desigualdade triangular)

Não entraremos nos detalhes do que é um espaço vetorial. Por ora, basta saber que os conjuntos  $\mathbb{R}^n$  e  $\mathbb{R}^{n \times n}$  dos vetores com  $n$  componentes e as matrizes  $n \times n$  são ambos espaços vetoriais com a soma e multiplicação por escalar.

---

Uma norma  $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$ , que associa à um vetor de  $\mathbb{R}^n$  um número real, será chamada **norma vetorial**. Similarmente, uma função  $\| \cdot \| : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$  é uma **norma matricial**.

# Norma Vetorial

---

Muitas normas vetoriais são dadas pela equação

$$\|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p} = \sqrt[p]{|x_1|^p + |x_2|^p + \dots + |x_n|^p}, \quad 1 \leq p < +\infty.$$

Exemplos de normas para  $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$  incluem:

- $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i| = |x_1| + |x_2| + \dots + |x_n|.$
- $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}. \quad (\text{norma Euclidiana})$
- $\|\mathbf{x}\|_\infty = \max_{i=1:n} |x_i| = \max\{|x_1|, |x_2|, |x_n|\}.$

## Exemplo 2

Para o vetor  $\mathbf{x} = [3 \ -4]^T$ , temos:

$$\|\mathbf{x}\|_1 = |3| + |-4| = 7,$$

$$\|\mathbf{x}\|_2 = \sqrt{3^2 + (-4)^2} = 5,$$

$$\|\mathbf{x}\|_\infty = \max\{|3|, |-4|\} = 4.$$

No GNU Octave, podemos calcular as normas  $\|\cdot\|_1$ ,  $\|\cdot\|_2$  e  $\|\cdot\|_\infty$  de um vetor  $\mathbf{x}$  usando respectivamente os comandos:

» `norm(x, 1)`

» `norm(x)` ou » `norm(x, 2)`

» `norm(x, inf)`


# Interpretação Geométrica

---

O conjunto

$$\mathcal{B}_1 = \{\mathbf{x} = (x, y) \in \mathbb{R}^2 : \|\mathbf{x}\|_1 \leq 1\},$$

corresponde à figura geométrica




# Interpretação Geométrica

---

O conjunto

$$\mathcal{B}_2 = \{\mathbf{x} = (x, y) \in \mathbb{R}^2 : \|\mathbf{x}\|_2 \leq 1\},$$

corresponde à figura geométrica




# Interpretação Geométrica

---

O conjunto

$$\mathcal{B}_\infty = \{\mathbf{x} = (x, y) \in \mathbb{R}^2 : \|\mathbf{x}\|_\infty \leq 1\},$$

corresponde à figura geométrica





## Normas Matriciais Subordinadas

---

Podemos identificar uma matriz  $\mathbf{A}$  com uma transformação linear

$$\mathbf{x} \mapsto \mathbf{Ax}.$$

Uma norma matricial subordinada  $\|\mathbf{A}\|$  mede **a maior distorção** efetuada pela transformação linear  $\mathbf{x} \mapsto \mathbf{Ax}$ . Formalmente, temos

$$\|\mathbf{A}\| = \max_{\mathbf{x} \in \mathbb{R}^n} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}.$$

Equivalentemente, escrevendo  $\mathbf{v} = \mathbf{x}/\|\mathbf{x}\|$ , concluímos que

$$\|\mathbf{A}\| = \max\{\|\mathbf{Av}\| : \|\mathbf{v}\| = 1\},$$


ou seja,  $\|\mathbf{A}\|$  é a maior distorção que  $\mathbf{A}$  faz em  $\{\mathbf{v} : \|\mathbf{v}\| = 1\}$ .

---

Observe que a norma matricial acima está subordinada ou é induzida pela norma vetorial!

## Exemplo da $\|\cdot\|_1$

Considere a matriz  $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$ . Geometricamente, temos



$$\|\mathbf{A}\|_1 = \max\{\|\mathbf{A}\mathbf{v}\|_1 : \|\mathbf{v}\|_1 = 1\} = 4.$$

## A Norma Subordinada $\|\cdot\|_1$

---

Pode-se mostrar que  $\{\mathbf{A}\mathbf{v} : \|\mathbf{v}\|_1 = 1\}$  é um politopo (generalização de um polígono) e o valor máximo de  $\|\mathbf{A}\mathbf{v}\|_1$ , para  $\|\mathbf{v}\|_1 = 1$ , é obtido num dos vértices.

---

Os vértices do politopo  $\{\mathbf{A}\mathbf{v} : \|\mathbf{v}\|_1 = 1\}$  são  $\pm\mathbf{a}_1, \pm\mathbf{a}_2, \dots, \pm\mathbf{a}_n$ , em que  $\mathbf{a}_1, \dots, \mathbf{a}_n$  são as colunas de  $\mathbf{A}$ , i.e.,  $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$ .


---

Portanto,  $\|\mathbf{A}\|_1$  é o valor máximo da soma dos valores absolutos das colunas de  $\mathbf{A}$ , ou seja,

$$\|\mathbf{A}\|_1 = \max\{\|\mathbf{a}_1\|_1, \dots, \|\mathbf{a}_n\|_1\} = \max_{j=1:n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

## Exemplo da $\|\cdot\|_\infty$

Considere a matriz  $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$ . Geometricamente, temos



$$\|\mathbf{A}\|_\infty = \max\{\|\mathbf{A}\mathbf{v}\|_\infty : \|\mathbf{v}\|_\infty = 1\} = 3.$$

## A Norma Subordinada $\|\cdot\|_\infty$

---

De um modo similar, pode-se mostrar que  $\{\mathbf{Av} : \|\mathbf{v}\|_\infty = 1\}$  é um politopo e o valor máximo de  $\|\mathbf{Av}\|_\infty$  é obtido num dos vértices.

---

Contudo, os vértices do politopo  $\{\mathbf{Av} : \|\mathbf{v}\|_\infty = 1\}$  são obtidos pelo produto  $\mathbf{Av}$ , em que  $\mathbf{v} = [\pm 1, \pm 1, \dots, \pm 1]^T$ .

---


Usando esse fato, podemos concluir que  $\|\mathbf{A}\|_\infty$  é o valor máximo da soma dos valores absolutos das linhas de  $\mathbf{A}$ , ou seja,

$$\|\mathbf{A}\|_\infty = \max\{\|\mathbf{a}_1^T\|_1, \dots, \|\mathbf{a}_n^T\|_1\} = \max_{i=1:n} \left\{ \sum_{j=1}^n |a_{ij}| \right\},$$

em que  $\mathbf{a}_i^T$  denota a  $i$ -ésima linha de  $\mathbf{A}$ .

## Exemplo da $\|\cdot\|_2$

Considere a matriz  $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix}$ . Geometricamente, temos



$$\|\mathbf{A}\|_2 = \max\{\|\mathbf{A}\mathbf{v}\|_2 : \|\mathbf{v}\|_2 = 1\} = 2.92081.$$

## A Norma Subordinada $\|\cdot\|_2$

---

Pode-se mostrar que  $\{\mathbf{Av} : \|\mathbf{v}\|_2 = 1\}$  é um hiper-elipse (generalização de uma elipse) e o valor máximo de  $\|\mathbf{Av}\|_2$ , para  $\|\mathbf{v}\|_2 = 1$ , é a metade do maior eixo.

---

Formalmente,  $\|\mathbf{A}\|_2$  é o maior valor singular de matriz  $\mathbf{A}$ .

---

No GNU Octave, podemos calcular as normas  $\|\cdot\|_1$ ,  $\|\cdot\|_2$  e  $\|\cdot\|_\infty$  de uma matriz  $\mathbf{A}$  usando respectivamente os comandos:

```
» norm(A, 1)
» norm(A) ou » norm(A, 2)
» norm(A, inf)
```

## Norma Consistente

---

Dizemos que uma norma matricial  $\|\cdot\|$  é consistente se

$$\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|,$$

para quaisquer matrizes  $\mathbf{A}$  e  $\mathbf{B}$ .

---

Todas as normas subordinadas são consistentes!

---

As normas subordinadas também satisfazem a desigualdade

$$\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \|\mathbf{x}\|,$$

para quaisquer matriz  $\mathbf{A}$  e vetor  $\mathbf{x}$ .



## Erro Absoluto e Erro Relativo

---

Suponha que resolvemos um sistema linear  $\mathbf{Ax} = \mathbf{b}$ , em que  $\mathbf{A} \in \mathbb{R}^{n \times n}$  é uma matriz não-singular e  $\mathbf{b} \in \mathbb{R}^n$ , usando um método numérico como, por exemplo, o método da eliminação de Gauss.

---

Vamos denotar por  $\tilde{\mathbf{x}}$  a solução encontrada pelo método numérico e  $\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}$  a solução exata.

---

Para avaliar a qualidade da solução produzida pelo método numérico, comparamos a solução numérica  $\tilde{\mathbf{x}}$  com a solução exata  $\mathbf{x}^*$  usando uma norma vetorial. Especificamente, calculamos o erro absoluto  $E_a$  ou o erro relativo  $E_r$  dados por:

$$E_a = \|\mathbf{x}^* - \tilde{\mathbf{x}}\| \quad \text{e} \quad E_r = \frac{\|\mathbf{x}^* - \tilde{\mathbf{x}}\|}{\|\mathbf{x}^*\|}.$$

## Resíduo

---

Uma desvantagem da análise que descrevemos anteriormente é que, na prática, não conhecemos a solução exata  $\mathbf{x}^*$  do sistema linear  $\mathbf{Ax} = \mathbf{b}$ . Portanto, não podemos calcular o erro.

---

Como alternativa, calculamos o chamado **resíduo absoluto**  $R_a$  ou o **resíduo relativo**  $R_r$  definidos por

$$R_a = \|\mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}\| \quad \text{e} \quad R_r = \frac{\|\mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}\|}{\|\mathbf{b}\|}.$$

---

Em algumas situações, é conveniente definir os vetores

$$\mathbf{e} = \mathbf{x}^* - \tilde{\mathbf{x}} \quad \text{e} \quad \mathbf{r} = \mathbf{b} - \mathbf{A}\tilde{\mathbf{x}},$$

chamados respectivamente **erro** e **resíduo**.

## Matriz Gerada Aleatoriamente

---

Para avaliar a qualidade da solução de um sistema linear  $\mathbf{Ax} = \mathbf{b}$  produzida pelo método da eliminação de Gauss, geramos uma matriz  $\mathbf{A} \in \mathbb{R}^{100 \times 100}$  cujos elementos  $a_{ij}$  possuem distribuição normal padrão.

---

Além disso, definimos  $\mathbf{x}^* = [1, \dots, 1]^T$  e  $\mathbf{b} = \mathbf{Ax}^*$ .

---

Determinamos a solução numérica  $\tilde{\mathbf{x}}$  usando o método da eliminação de Gauss e calculamos o erro e o resíduo relativo.

---

Repetimos o processo 1000 vezes. A média dos erros e resíduos relativos foram  $1.3 \times 10^{-12}$  e  $6.0 \times 10^{-14}$ , respectivamente.

---

Note que o resíduo forneceu uma boa estimativa para o erro!

## Comandos do GNU Octave

---

```
» for i=1:1000
    A = randn(100,100); xs=ones(100,1);
    b=A*xs; xt=A\b;
    E_r(i)=norm(xs-xt,inf);
    R_r(i)=norm(b-A*xt,inf)/norm(b,inf);
end
» [mean(E_r),mean(R_r)];
ans =
    1.6535e-13    2.2155e-15
```

## Matriz de Hilbert

---

Considere a matriz  $\mathbf{A} \in \mathbb{R}^{100 \times 100}$  cujos elementos são

$$a_{ij} = \frac{1}{i+j-1}.$$

Definimos  $\mathbf{x}^* = [1, \dots, 1]^T$ ,  $\mathbf{b} = \mathbf{Ax}^*$  e determinamos a solução numérica  $\tilde{\mathbf{x}}$  usando o método da eliminação de Gauss.

---

O erro relativo e o resíduo relativo foram

$$E_r = \frac{\|\mathbf{x}^* - \tilde{\mathbf{x}}\|_\infty}{\|\mathbf{x}^*\|_\infty} = 1.38 \quad \text{e} \quad R_r = \frac{\|\mathbf{b} - \mathbf{A}\tilde{\mathbf{x}}\|_\infty}{\|\mathbf{b}\|_\infty} = 1.46 \times 10^{-15}.$$

Ao contrário do exemplo anterior, temos resíduo relativo muito pequeno mas um erro relativo grande.

## Comandos do GNU Octave

---

```
» A = hilb(100); xs=ones(100,1);  
» b=A*xs; xt=A\b;  
warning: matrix singular to machine precision,  
rcond = 1.14558e-21  
» R_r=norm(b-A*xt,inf)/norm(b,inf)  
R_r = 1.4554e-15  
» E_r=norm(xs-xt,inf)  
E_r = 1.3774
```

## Sistemas Lineares Mal-Condicionados

---

Em termos gerais, um sistema linear  $\mathbf{Ax} = \mathbf{b}$  é mal-condicionado se pequenas perturbações na matriz  $\mathbf{A}$  ou no vetor  $\mathbf{b}$  causam grandes variações na solução.

---

Nesse caso, devido aos erros na representação e operações de pontos flutuantes, não devemos esperar uma solução precisa de um método numérico!

---

Além disso, num sistema linear mal-condicionado, o resíduo pode não revelar a natureza do erro!

---

O condicionamento de uma matriz  $\mathbf{A}$  é definido em termos de sua norma e a norma de sua inversa.

Sabemos que os vetores **e** (erro) e **r** (resíduo) satisfazem:

$$\mathbf{r} = \mathbf{A}\mathbf{e} \quad \text{e} \quad \mathbf{e} = \mathbf{A}^{-1}\mathbf{r}.$$

Sendo  $\|\cdot\|$  uma norma subordinada, tem-se:

$$\|\mathbf{r}\| \leq \|\mathbf{A}\|\|\mathbf{e}\| \quad \text{e} \quad \|\mathbf{e}\| \leq \|\mathbf{A}^{-1}\|\|\mathbf{r}\| \quad \Longrightarrow \quad \frac{\|\mathbf{r}\|}{\|\mathbf{A}\|} \leq \|\mathbf{e}\| \leq \|\mathbf{A}^{-1}\|\|\mathbf{r}\|.$$

Analogamente, das equações  $\mathbf{b} = \mathbf{A}\mathbf{x}^*$  e  $\mathbf{x}^* = \mathbf{A}^{-1}\mathbf{b}$ , obtemos

$$\|\mathbf{b}\| \leq \|\mathbf{A}\|\|\mathbf{x}^*\| \quad \text{e} \quad \|\mathbf{x}^*\| \leq \|\mathbf{A}^{-1}\|\|\mathbf{b}\| \quad \Longrightarrow \quad \frac{1}{\|\mathbf{A}^{-1}\|\|\mathbf{b}\|} \leq \frac{1}{\|\mathbf{x}^*\|} \leq \frac{\|\mathbf{A}\|}{\|\mathbf{b}\|}.$$

Combinamos as inequações, obtemos:

$$\frac{1}{\|\mathbf{A}\|\|\mathbf{A}^{-1}\|\|\mathbf{b}\|} \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|} \leq \frac{\|\mathbf{e}\|}{\|\mathbf{x}^*\|} \leq \|\mathbf{A}\|\|\mathbf{A}^{-1}\| \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}.$$



## Número de Condição de uma Matriz

---

O número de condição de uma matriz  $\mathbf{A}$ , também chamado condicionamento de  $\mathbf{A}$ , é definido por

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|.$$

---

Vale a seguinte relação entre o erro relativo e o resíduo relativo:

$$\frac{R_r}{\text{cond}(\mathbf{A})} \leq E_r \leq \text{cond}(\mathbf{A}) R_r.$$

- Se  $\text{cond}(\mathbf{A})$  é próximo de 1, o erro relativo  $E_r$  e o resíduo relativo  $R_r$  são próximos.
- Se  $\text{cond}(\mathbf{A})$  é grande, o erro relativo pode ser muito maior que o resíduo relativo.

O número de condição de uma matriz **A** pode ser calculada no GNU Octave usando o comando:

```
» cond(A)
```

---

O comando

```
» rcond(A)
```

fornece o recíproco  $1/\text{cond}(\mathbf{A})$ , obtido usando a norma-1.

Note que **A** é mal-condicionada se  $\text{rcond}(\mathbf{A})$  é próximo de zero.

---

Calculamos o condicionamento da matriz de Hilbert como segue:

```
» cond(hilb(100))
```

```
ans = 5.9832e+19
```

---

Com base nos números do exemplo anterior, temos

$$\underbrace{1.38}_{E_r} \leq \underbrace{5.98 \times 10^{19}}_{\text{cond}(\mathbf{A})} \underbrace{1.46 \times 10^{-15}}_{R_r} = 8.71 \times 10^4.$$

## Considerações Finais

---

Na aula de hoje apresentamos os conceitos de norma vetorial e norma matricial subordinada.

---

Vimos como esses conceitos podem ser usados para determinar o erro relativo de um sistema linear.

---

Vimos também o conceito de resíduo relativo e mostramos que ele representa o erro relativo se o condicionamento de  $\mathbf{A}$  for próximo de 1.

---

Se  $\text{cond}(\mathbf{A})$  é grande, dizemos que a matriz é mal-condicionada. Nesse caso, não podemos confiar na solução fornecida por um método numérico.

---

Muito grato pela atenção!